马思远

中国香港 | siyuan.ma.jasper@gmail.com | 个人主页 | Google Scholar | GitHub

教育背景

香港中文大学 (CUHK) 香港
计算机科学与工程博士，导师：刘威杨助理教授 *2026.08 - 2030.07（预计）*

- 研究方向：具身多模态大语言模型、世界模型评测、物理推理。

北京大学 (PKU) 北京
理论与应用力学（工程与科学计算）理学学士 *2020.09 - 2025.07*

- 研究方向：多模态大语言模型安全；荣誉：北京大学三好学生（Top 10%）。

研究与实习经历

字节跳动 北京 / 深圳
研究实习生，数据研究 *2026.05 - 至今*

- 围绕具身视频理解、视频世界模型评测、动作视频数据构建和物理推理评测模型开展研究。

西湖大学 杭州
研究助理，导师：温研东助理教授 *2025.09 - 2026.05*

香港中文大学 香港
研究助理，导师：刘威杨助理教授 *2025.09 - 2026.05*

威斯康星大学麦迪逊分校 美国麦迪逊
研究助理，导师：肖超纬助理教授 *2023.12 - 2024.09*

代表性论文

* 共同一作。

具身多模态模型与世界模型评测

- **Ma, S.***, Qi, Y.*, Ye, C.*, Peng, R., Xu, X., Lin, Z., Cai, Z., Huang, Y., Liu, W., Wang, S., Wen, Y. RoboJudge: Multimodal Language Models as Judges for Embodied Video Generation. **CoRL 2026 TAG Workshop**, Oral, 2026. [arXiv] [Project] [Code]
- Qi, Y.*, Xu, X.*, Guo, Z.*, **Ma, S.***, Zhang, R., Chen, X., An, R., Xing, R., Zhang, J., et al., Wong, L. L. S. MME-CoF-Pro: Evaluating Reasoning Coherence in Video Generative Models with Text and Visual Hints. **ECCV**, 2026. [arXiv]
- Qi, Y.*, Zhao, H.*, Guo, Z.*, **Ma, S.**, Chen, Z., Han, Y., Zhang, R., Lin, Z., Xin, S., et al., Wong, L. L. S. BEAR: Benchmarking and Enhancing Multimodal Language Models for Atomic Embodied Capabilities. **ICML**, 2026. [arXiv]

多模态 AI 安全

- Luo, W., Zhang, Q., Lu, T., Liu, X., Ma, B., Chiu, H.-C., **Ma, S.**, et al. Your Cursor is Not Secure: Command Line Interface Agent Can Expose Realistic Risks Through Tactics, Techniques, and Procedures. **EMNLP Findings**, 2026.
- Ma, Y., Wang, J., Wang, F., **Ma, S.**, Li, J., Pan, J., Li, X., Huang, F., Sun, L., Li, B., et al., Xiao, C. Benchmarking Vision Language Model Unlearning via Fictitious Facial Identity Dataset. **ICLR**, 2025.
- Luo, W.*, **Ma, S.***, Liu, X.*, Guo, X., Xiao, C. JailBreakV-28K: A Benchmark for Assessing the Robustness of Multimodal Large Language Models against Jailbreak Attacks. **COLM**, 2024. [Paper] [Project] [Code]

代表性项目

RoboJudge：多模态大语言模型作为具身视频生成评测器 第一作者
CoRL 2026 TAG Workshop Oral *2026.06 - 2026.09*

- 构建 RoboJudge-Bench，系统评测具身视频的物理合理性与指令遵循能力；基准包含 800 条视频，覆盖 8 个数据源与 10 个视频生成模型。
- 构建 RoboJudge-Train（12K 条视频、25K 组人工评分与推理），训练专用 RoboJudge-9B，与人工评分总体 Pearson 相关系数达到 0.719。

JailBreakV-28K：多模态越狱攻击评测基准 共同第一作者

COLM 2024；SafeBench Award *2024*

- 构建 28K 多模态越狱评测集；获得 Center for AI Safety 的 $20,000 SafeBench Award，并被 NVIDIA garak 和 Microsoft PyRIT 集成。

学术服务

- CoRL 2026 Workshop on The Action Gap (TAG)，组织者与 Program Chair。
- 审稿人：ICLR 2027、EMNLP 2026。